

以反馈推进研究， 以研究结果改进策略

Yingze Li Dong Wang Ben Wu Xianglong Liu Hongzhi Wang*

Harbin Institute of Technology * 通讯作者

摘要

EAR (Effective Auto Research) 是一套开源科研自动化系统，面向问题发现、自主数学研究与评审回应。它以减少研究者的主动投入为目标，同时将研究质量要求与机器预算作为约束。科研往往在计划改变时向前推进：新文献改变选题判断，反例迫使推导转向，评阅将稿件送回修订。同类工作已将自动化带入选题、实验与写作；从这些环节走向持续研究，还需要让材料能够接续、反馈能够指导行动，并让一次任务的经验进入下一次执行。

EAR 的核心理念是以反馈推进研究，以研究结果改进策略。AutoVibeIdea 通过文献检索、批判与树搜索，将研究方向收敛为可执行提案；AutonomousMath 的内循环推进推导、验证与稿件修订，外循环用完整研究结果检验并演化执行策略；AutoRebuttal 从审稿疑虑与已有证据出发，补齐缺口、比较并修订回应。三个模块可独立使用，也可由研究者通过提案、稿件与评阅材料接续不同阶段的工作。方向选择、关键技术验收与最终审阅由研究者掌握。^[1]

历史评估中，持续修订将同一组 28 篇稿件的当前版本模型评阅通过数从 3 增至 12；所选演化策略较初始策略获得更多通过结果，每个通过结果所需的研究调用减少 52.8%。这些结果为 EAR 持续推进研究、改进执行策略的设计提供了初步支持。^[10]

关键词 科研自动化；主动人时；批判性树搜索；研究策略演化；证据驱动回应

CONTENTS

目录

1	引言	3
1.1	EAR：让研究持续推进	3
1.2	持续研究的难点：把反馈变成下一步	3
1.3	EAR 的核心理念：反馈推进研究，结果改进策略	4
2	系统设计与方法	5
2.1	系统架构：把研究状态保留下来	5
2.2	问题发现：批判性树搜索，让问题逐轮具体化	6
2.3	数学研究：内循环做研究，外循环改进做法	8
2.4	评审回应：先处理关键疑虑，再组织回应	10
3	评估与结果	12
3.1	评估协议：尝试、稿件与通过分别计数	12
3.2	稿件修订：当前通过数从 3 增至 12	13
3.3	G3 所选策略：更多通过，更少研究调用	15
3.4	评分预测：提分与不变可辨，降分仍难判	18
4	结论	19
	参考文献与公开资料	20

阅读导航 第1章介绍 EAR 的研究对象与核心理念；第2章展开三个工作流，重点解释数学研究的双循环；第3章呈现稿件修订、策略比较和回应评分预测的结果及评价条件。

1 引言

1.1 EAR：让研究持续推进

科研中的许多判断，发生在计划改变的时候。刚找到的一篇近邻论文，可能让一个高分选题失去继续做的理由；一个反例，会迫使证明换一条路线；评阅指出的缺口，又会把已经成形的稿件送回推导或实验。研究由这些具体的转折向前推进。自动化系统也需要跟得上：保存已经得到的材料，理解新证据改变了什么，然后继续工作。

EAR (Effective Auto Research) 是一套开源科研自动化系统，面向问题发现、自主数学研究和评审回应。我们希望研究者给出方向和约束之后，检索、尝试与修订能够持续进行；再次介入时，有新的产物可以检查，也有清楚的理由说明哪些路线值得继续。

EAR 提供三个可独立使用的工作流。问题发现从方向和资源条件出发，比较文献与候选，形成研究提案；数学研究推进具体目标，交付论证、实现与稿件；评审回应依据论文、审稿意见和已有证据，组织回答并保留依据。研究者可以通过这些材料接续不同阶段的工作。^[1]

持续推进还需要积累研究做法。在数学研究模块中，EAR 将两者放进一对循环：内循环完成当前研究，外循环用完整研究结果检验执行策略。选题条件、证明组织和修订指令因此有机会随研究经验改进。研究结果与研究做法，构成 EAR 关注的两个对象。系统既要完成当前任务，也要从成功、失败和评阅中获得下一次执行的依据。

把有限的人时留给关键判断

科研中的主动投入分散在阅读、编排、检查和返工中。每次中断之后重新恢复上下文，也要付出额外代价。^[6,7] EAR 因而把研究者的主动人时置于设计目标的中心：

$$\min H \quad \text{subject to} \quad Q \geq Q_{\min}, \quad C \leq B. \quad (1)$$

H 表示主动人时， $Q_{\min}$ 为要求达到的研究质量， C 为模型、工具与算力费用， B 为机器预算。日历周期 T 单独记录，并可作为截止时间约束；多人协作时， H 为所有参与者实际投入的总和。

这个目标要求核算完整的工作负担。检索阅读、任务编排、技术检查、模型错误修复、失败路线返工和最终审阅都计入人时，新增审核工作也必须计入。无人值守的等待属于日历周期，期间没有主动工作的部分不计入 H 。本文报告过程记录、模型评阅和调用数量，主动人时的实际节省仍待直接测量。

1.2 持续研究的难点：把反馈变成下一步

现有工作已经把自动化带进科研的不同环节。ResearchAgent 从文献出发，借助评阅反馈迭代研究点子；The AI Scientist 将点子、实验、结果分析和写作串成科研流程；Paper2Rebuttal 围绕审稿疑虑整理证据与回应计划。GEPA 则把执行轨迹和文本反馈用于提示演化。这些探索为持续研究提供了重要起点。^[2,3,4,5]

实际使用时，研究者首先面对的是材料的接续。一份提案进入推导之后，它的假设、近邻文献和验证计划仍然有用；一段证明失败之后，反例和失败位置也应当留下。若这些判断散落在不同交互中，接手工作就需要重新阅读和组织。保存怎样的研究状态、如何交接、何时需要人介入，都会影响长期使用的负担。

反馈的接续更进一步。一个低分并没有直接给出下一步：缺口可能在证明，也可能在贡献或表达。系统需要把评阅意见送到相应的研究动作中，让推导得到修复、证据得到补充，或让稿件的主张与已有结果重新对齐。

最后，经验需要进入下一次研究。一条看起来合理的新指令，仍要经历选题、技术尝试、写作和评价，才能知道它是否改善了执行。研究做法的更新，需要由完整任务的结果来决定。表1 概括了相关工作各自关注的对象。

工作	研究或优化对象	反馈的作用
ResearchAgent ^[2]	基于文献的问题、方法与实验构想	评阅意见用于迭代研究点子
The AI Scientist ^[3]	机器学习点子、实验、结果与论文	实验结果支持迭代，自动评阅用于稿件评价与知识档案
GEPA ^[4]	语言模型系统中的提示	执行轨迹与反思用于提示变异和组合
Paper2Rebuttal ^[5]	评审疑虑、证据与回应计划	先形成可检查计划，再组织回应
EAR ^[1,10]	研究任务及其执行策略	当前研究接受反馈，数学外循环用完整研究检验执行策略

表 1: 相关工作的研究对象与反馈机制。表中比较设计定位，系统间的同任务性能尚未测试；The AI Scientist 对应 2024 年原始系统，不包含后续 AI Scientist-v2。

EAR 把这三处接续放在同一设计目标下：研究材料支持继续执行，反馈落实为具体修改，完整研究结果决定后续策略。对于需要反复筛选方向、推进数学与算法任务，或处理评审疑虑的研究者，这种组织方式提供了持续工作和检查关键取舍的基础。

1.3 EAR 的核心理念：反馈推进研究，结果改进策略

在数学模块中，EAR 把一次完整研究作为策略演化的评价单元。内循环围绕当前目标检索、推导、验证与修订；外循环让候选策略各自执行研究，再依据稿件、评价和失败原因决定保留或修改。一次研究中暴露的问题，可以进入下一次的选题要求、证明组织和修订指令。每次研究，都应当为下一次研究留下更好的起点。

这一理念也体现在另外两个工作流中。问题发现把新文献用于重新判断候选价值：有依据的方案继续精修，发生碰撞或不可行的路线保留退出理由。评审回应先寻找疑虑

对应的证据，再补齐缺口并组织回答。反馈因此能够改变投入方向，也能落到具体的技术工作上。

人的判断贯穿其中。研究者确定方向与质量标准，检查关键技术结论，并对最终稿件和回应负责。EAR 承担可持续执行的检索、尝试和修订，同时保留候选取舍、版本变化与策略修改的依据。这种分工希望让研究者每次返回时，都能从已经推进的工作中继续判断。

从设计主张到可观察的结果 在 G0-G3 的同一组 28 个完成稿件中，三轮修订后的当前版本模型评阅通过数由 3 增至 12。第3.2 节给出逐轮轨迹与最佳版本结果；这里的通过采用历史模型评阅规则。^[10]

下文先展开系统架构与三个 workflow，再用稿件修订、策略比较和回应评分预测检查这些机制的表现。

2 系统设计与方法

EAR 的三个 workflow 围绕可保存的研究状态推进：已有材料进入下一轮执行，新证据改变后续行动。数学研究在此基础上加入策略演化，让完整研究的结果参与执行做法的更新。

2.1 系统架构：把研究状态保留下来

一次执行从方向、资源和交付要求出发，调用工具完成检索、推导辅助、实现与评价，并留下研究材料和反馈。下一轮据此继续工作。图1 展示提案、稿件与评阅材料之间的关系；三个模块可独立接收输入，跨阶段的材料交接由研究者组织。本文的效果证据来自各模块的独立记录，跨模块完整流程尚未单独评估。




图 1: EAR 的研究任务与产物衔接。三个 workflow 分别可用，提案、稿件和评阅材料可以成为后续输入；关键判断与研究责任由人承担。

工作流	输入与交付	人保留的判断
问题发现	方向与条件 → 文献比较、候选、提案	问题价值与执行路径
数学研究	方向或提案 → 论证、代码、稿件与评价	关键技术结论与验收
评审回应	论文、评审与证据 → 回应及证据账本	主张边界与最终责任


表 2: 三个工作流的输入、交付与人工职责。研究者通过提案、稿件和评阅材料组织阶段交接。

交接做过的判断，研究才能继续

研究中途换一个执行者，最需要交接的是做过的判断：采用了哪些设定，哪些文献最接近，证明推进到了哪里，哪条路线已经失败。EAR 保存这些状态及后续验证计划，使工作能够从已有结果继续。评价记录同时标明实际工具反馈与宿主自审的来源，研究者可以据此检查重要取舍。^[1]

2.2 问题发现：批判性树搜索，让问题逐轮具体化

问题发现从研究方向与资源条件起步，把候选逐步展开为明确的问题、假设、方法和验证计划。每次扩展都引入新的检索与批判，节点的价值随证据更新，下一次投入也随之调整。图2 给出候选扩展和分支退出的关系。



UCT 引导优先扩展；节点逐步具体化，检索证据持续改变取舍。

图 2: 候选扩展与批判性搜索。检索和评价更新节点价值，碰撞、不可行或重复的分支可以退出，退出依据仍然保存。

2.2.1 每次扩展，都重新检索与批判

当前实现用 UCT 引导 best-first 扩展。模型提出子节点，评价工具更新访问次数与节点价值，并沿父链回传。每个新候选至少重新检查新颖性和研究适配度；选择节点时，综合评分、可核查的文献重合、验证规则与结构信号共同参与判断。搜索直接评价展开后的候选，不使用随机 rollout 模拟终局。^[1,2]

表3 列出四类评价及组合权重。分数与理由、检索来源一起保存，使继续扩展某个分支的依据可追溯。不同 Agent 承担生成、批判和评价职责；评阅者画像的调用范围，以实际提示和执行记录为准。

字段	检查的研究问题	权重
Novelty	最近工作与核心机制是否具有实质差异	.25
Venue	研究价值、严谨性与目标要求是否匹配	.35
Strategic	是否可证伪、证据可得，是否符合资源条件	.20
Feasibility	实现复杂度、算力、数据与时间线是否可行	.20

表 3: 当前搜索评价字段与权重。评价结果影响下一次扩展，来源和理由为复核提供依据。

2.2.2 从研究意图到可执行提案

研究者给出方向、资源约束与关键追问，Claude Code Harness 组织任务并调度工具，Codex MCP 返回候选、批判、评分与建议。图3 展示选题模块的一种交互接入方式：反馈返回当前任务，筛选与精修结果保存下来，成为下一步工作的输入。




图 3: 选题模块的交互式接入。研究者给出约束并选择下一步，Harness 与评价工具交换反馈，保存候选、文献和精修结果。

候选筛选与提案精修可以分别进行。筛选时，评价工具读取候选的核心主张与近邻文献，判断新颖性和实质差异，并给出继续或放弃的建议。精修阶段沿保留的候选展开，补齐研究设定与验证计划。早期接入以分阶段交互推进，当前树搜索进一步组织了候选扩展；两者保留了同样重要的材料交接。^[1]

2.2.3 退出理由也是研究产物

候选与已有工作实质重合，或在给定条件下不可行时，搜索可以停止该分支。EAR保留节点、来源、差异分析与退出理由，后续工作仍能利用这部分负向证据。留下的方案则围绕确定的问题锚点继续精修，明确假设、主要论据、实现接口和最低验证计划，形成可执行提案。

过程案例 E1：新增近似工作，使高分候选退出

在一次早期分阶段复判中，补充检索在两个候选周围共找到三项近似工作。候选 A 的新颖性由 8/10 降至 4/10，继续研究的建议转为放弃；候选 B 由 8/10 降至 5/10。转折来自新增文献：系统重新比较核心差异，随之修改分数、理由和投入建议。^[10]

最初的检索未充分覆盖近邻工作，候选因而显得更有差异。补充检索改变了这个判断，也改变了后续行动。这段记录展示了复筛如何影响投入决定。它来自早期分阶段流程，与当前 UCT 搜索版本不同，算法间的性能比较仍需相应对照。


2.3 数学研究：内循环做研究，外循环改进做法

数学与算法研究可以把技术疑虑落实到具体命题、反例、构造和数值检查中。EAR用内循环沿这些线索推进当前任务，再把一次完整研究的结果交给外循环，检验采用的执行策略。图4 展示研究修订与策略演化之间的嵌套关系。

2.3.1 保留研究状态，沿具体缺口修订

内循环围绕明确目标开展选题、推理、证明或构造、实现、检查与写作。精确命题、失败的证明步骤、反例、数值验证与实验对照都进入研究状态。一次尝试结束后，下一步可以沿尚未解决的缺口继续；达到交付条件时完成稿件，无法继续时记录退出。

评阅指出证明缺口，修订就返回推导；实现或验证存在问题，则补充技术检查；贡献不足需要重新审查范围与主张，表达问题进入稿件重写。历史运行在初评后执行三轮修订与再评阅，并恢复平均评分最高的稿件版本。每轮修改及评价变化都被保留，当前轮轨迹与最终交付版本因此分别统计，评价协议见第3.1 节。



每个候选策略运行完整研究；历史评价允许各策略自行寻找研究目标。

图 4: 数学研究的双循环。内层推进当前任务，外层依据完整研究结果比较与更新策略，并保留初始策略。历史策略可自行寻找具体目标。

2.3.2 策略要经受一次完整研究

外循环的基因组表示一套候选研究策略。历史版本由阶段提示与策略参数构成，涵盖目标筛选、证明组织、写作和修订。当前可移植版本将可修改范围扩展到任务程序、提示、技能、工具流程与配置，基础模型权重保持固定。初始策略与候选策略分别保存，谱系、研究结果和失败原因构成后续选择的依据。^[1,4]

一个策略是否值得采用，要由它执行研究的结果回答。每个候选都要尝试完整研究，目标选择、技术进展、稿件与评阅结果，以及失败出口，都进入外循环选择。在当前可移植版本中，任务列表、终审与标准固定在候选的修改范围之外；历史实验允许策略自行选择具体研究目标。第3.1 节按这一历史设定解释结果。

策略更新采用四种操作。精英保留延续表现较好的策略；定向变异针对退出原因、技术缺口或低分意见修改父策略；语义交叉组合两个父策略的互补指令；探索尝试较大变化。历史改动具体落在选题与论证上：缩短候选清单，提高目标与贡献要求，并提前要求核心引理和可行证明路线。更新后的策略再次执行研究，接受结果检验。

2.3.3 成功与退出，都进入适应度

历史 episode 的适应度按下式计算：

$$F(e) = \begin{cases} q_{\text{best}}(e), & \text{完成稿件且具有有效评分,} \\ 0.5, & \text{研究退出,} \\ 0, & \text{筛选淘汰,} \\ -0.5, & \text{没有目标或搜索失败,} \\ -2, & \text{预算耗尽或贡献过于平凡.} \end{cases} \quad (2)$$

q_{best} 为初评与修订中保留的最高稿件均分。稿件完成但所有评分尝试都失败时，历史实现采用 3.0 回退值。研究退出、筛选淘汰、搜索失败与预算耗尽保留不同适应度，使成功写作之前的取舍与失败也进入策略评价。

当轮策略按平均 F 排序选择。历史精英档案另用以下组合指标保存策略表现：

$$A_{\text{hist}} = \frac{1}{3} \left(\frac{\bar{F} + 2}{12} + w + a \right), \quad (3)$$

其中 w 为稿件完成率， a 为历史模型评阅通过率。当前可移植版本等权组合归一化质量、完成率与固定终审通过率：

$$A_{\text{portable}} = \frac{1}{3} \left(\frac{\bar{q}_{\text{clip}}}{10} + w + a_{\text{final}} \right). \quad (4)$$

当前质量分数按约定规则裁剪并归一化；组合得分相当时，再比较调用与返工。平均 F 用于历史当轮选择， A_{hist} 用于历史档案， A_{portable} 用于当前版本。调用效率另按执行记录核算。^[1,10]

2.4 评审回应：先处理关键疑虑，再组织回应

评审回应从论文、审稿意见、已有证据与截止时间出发。它先判断疑虑对应的证明或实验是否已经存在，再安排必要的补充工作，组织回应草稿并保留依据。图5 展示从疑虑到证据、再到回答的过程。

2.4.1 先找到疑虑对应的证据

几位审稿人可能从不同角度提出同一疑虑。EAR 先归并相关意见，找到论文中的对应论据，再分辨问题出在解释、证明还是实验。解释不足时，把已有证据组织清楚；确实存在技术缺口时，再安排补充研究。同一项证明或实验可以回答多条相关意见，证据账本记录主张与出处。^[1,5,9]

社区公开的回应方法与作者经验提供初始策略。候选在回答顺序、证据选择与组织方式上有所不同，优先处理影响论文判断的疑虑。资源约束下的目标写为：




图 5: 从论文和评审定位疑虑及证据。已有证据足够时直接起草；有技术缺口时先补齐。模型反馈用于修订，作者审阅关键内容与最终回应。

$$\max_{\theta} \mathbb{E}[\Delta R \mid \text{Context}, \theta] \quad \text{subject to} \quad H \leq H_B, C \leq B, T \leq D. \quad (5)$$

Context 包含论文、评审与已有证据， θ 为回应策略， ΔR 为希望改善的评分， H_B 为人时上限， D 为截止时间。该式表达设计目标；现有预测测试检查反馈组件，过程记录检查策略调整，生成回应对真实评分的影响尚未直接测量。

2.4.2 保留好草稿，追踪未解疑虑


候选策略可以优先说明已有证据，围绕关键疑虑组织论证，或先补齐缺失验证。它们使用同一份论文与审稿材料，把工作安排与回答方式作为比较对象。图6 展示草稿和反馈怎样进入下一轮。

较好的草稿保留下来，未解疑虑、证据缺口与修改建议随它进入下一轮。这是一次黑盒优化：系统比较候选回应，读取诊断反馈后调整策略，无需计算评分对策略的导数。评价同时检查疑虑覆盖和论据依据，并预测评分上涨、不变或下降；预测能力在第3.4 节单独测试。

过程案例：两轮反馈带来策略调整

一份匿名历史记录每轮比较三种策略：优先依据已有证据、围绕关键疑虑组织论证，以及分阶段补证据。第一轮所选的证据优先策略未达到历史内部代理的停止要求；第二轮继承草稿与修改建议，改用关键疑虑优先策略后触发停止条件。记录展示了反馈如何改变写法，尚未用当前门槛重新评阅，也未测量真人评分变化。^[10]

历史流程在草稿通过内容评价后停止本轮其余策略尝试，再核对回应是否忠实于论文与证据、表述是否准确。检查发现的问题返回修订，最终草稿交给作者审阅。新增技术结论、证据有效性与最终回应由作者确认。



比较候选，保留较好版本，按反馈修改，再比较。

图 6: 回应策略从社区方法与作者经验初始化。候选共享材料，模型评价与事实检查形成反馈；下一轮继承较好草稿、证据、未回答的问题和修改建议。

3 评估与结果

评估检查两种改进：稿件在持续修订中如何变化，研究策略在演化后取得怎样的结果。回应评分预测另行测试，用于判断反馈组件是否能识别已有回应之后的评分变化。

3.1 评估协议：尝试、稿件与通过分别计数

本次统计在查看档案后选取 G0 初始化及 G1–G3 三代演化作为展示窗口，档案还包含后续代。该阶段共记录 64 次研究尝试、630 次研究调用、28 个完成稿件和 15 个最佳保留版本的模型评阅通过结果。失败与未完成稿件的尝试全部计入总数。^[10]

单位或定义	在本报告中的含义
研究尝试（episode）	一次完整研究执行，失败也进入总数和调用统计
研究调用	历史驱动器记录的研究阶段执行器启动次数
完成稿件	产生所要求的稿件产物；与评阅通过分开记录
当前轮通过	该评分轮正在评阅的版本满足历史 Accept 规则
最佳保留版本通过	最高均分版本恢复后，采用该版本的评价标签
固定内循环子集	同一组 28 个完成稿件，跟踪初评与三轮修订
策略比较批次	每代初始策略与所选策略各对应四次研究尝试

表 4: 数学评估的单位与版本口径。完成、当前轮通过和最佳版本通过分别回答不同问题。

历史评阅与版本恢复

历史评阅每轮启动三个新 Codex 会话, 按 SAC 模拟量表评价稿件, 至少一票 Accept 即记为通过。初评之后进行三轮修订与再评阅, 最终恢复平均评分最高的版本, 并采用它的评价标签。这里的通过指历史模型评阅通过, 与真实会议录用及当前可移植版本的固定终审分别处理。

稿件修订只跟踪已经完成的 28 个稿件; 失败和未完成尝试保留在外循环统计中。每代初始策略与所选策略的批次各含四次尝试, 其中 G0、G1 的两个角色指向同一批次, 总账中只计一次。

策略比较与调用覆盖

历史策略会从给定方向中自主选择具体目标, 比较结果因此包含选题与执行做法的共同影响。各批次为自适应、非配对的历史运行, 未预选同一命题, 也未设置等 token、美元或人时预算及演化算子消融。我们分别列出所选策略、整代种群与整个窗口的计数, 使采用一个策略和搜索策略的投入都能被看到。

调用账本包括研究阶段启动、独立评阅会话, 以及根据非初轮评分推算的修订尝试。每组评阅包含三个独立会话, 合计时按会话计数, 组数不重复相加。合计调用数是成本代理, 尚未覆盖策略教练与育种、内部模型及工具调用、未记录重试、完整计费 token、美元和主动人时。

过程证据与预测指标

问题筛选案例 E1 来自早期分阶段复判, 回应两轮记录采用历史内部代理停止规则。它们展示执行过程中的判断变化。回应预测则使用既有论文、评审与回应, 以最终评分减初始评分的符号为标签。数学统计可由公开聚合数据核对; 回应预测保留来源报告的指标值。评价协议随报告公开。

3.2 稿件修订: 当前通过数从 3 增至 12

同一组 28 个完成稿件经历初评与三轮修订, 当前通过数依次为 3、10、10、12, 均分由约 4.65 升至 5.67。图7 展示当前版本轨迹, 表5 同时列出截至各轮的最佳保留版本。




图 7: G0-G3 的固定 28 稿件子集。图展示初评及三轮修订中当前版本的通过数与平均评分；各轮最佳保留版本结果见表5。

评分轮	当前通过数	当前均分	最佳保留通过数	最佳保留均分
初评	3	4.648	3	4.648
修订 1	10	5.247	10	5.270
修订 2	10	5.498	12	5.568
修订 3	12	5.675	15	5.790

表 5: 固定稿件子集的逐轮结果。每轮均为 28 个稿件；均分展示到三位小数，完整聚合值保存在发布数据中。均分由来源记录的分数和复算。

当前通过比例由 $3/28 = 10.7\%$ 增至 $12/28 = 42.9\%$ ，初末均分差约 1.03。最后轮与初轮相比，27 个稿件均分提高、1 个下降。修订后，这组稿件的模型评阅结果整体改善；记录尚未设置仅重新评分的对照，因而不能单独估计依据反馈修订的因果收益。^[10]

保留最高均分版本，处理修订中的回落

版本轨迹中也有回落。13 个稿件的最后轮均分低于各自历史最佳均分，3 个稿件的最佳版本通过、最后轮未通过。恢复最高均分版本后，最终保留稿件的通过数为 15；最后轮当前通过数为 12。这些回落说明了保留版本历史的实际作用：修订继续进行，已有的较好稿件仍能交付。

3.3 G3 所选策略：更多通过，更少研究调用

各代所选策略的历史通过率见图8。每个点对应四次完整研究尝试，失败和未完成尝试也在分母中。G0、G1 的所选批次均无通过结果，G2 为 2/4，G3 为 3/4；各代使用分别选出的策略及研究目标。




图 8: G0 初始化及 G1–G3 三代演化中，所选策略通过率依次为 0%、0%、50%、75%。各点为四次历史研究尝试；不是同一策略在固定任务上的连续测量。

把上一轮遇到的问题，变成下一轮的改法

外循环把退出原因与评阅意见带回策略修改。历史记录中的改动包括缩短候选清单、提前要求核心引理与证明路线，以及提高贡献要求。后续批次再用研究结果检验这些做法。表6 列出初始与所选策略的批次计数，表7 列出全部候选的种群总账。

代	初始通过／尝试	所选通过／尝试	初始研究调用	所选研究调用
G0	0/4	0/4	53	53
G1	0/4	0/4	40	40
G2	0/4	2/4	24	45
G3	2/4	3/4	41	29

表 6: 初始策略与每代所选策略的历史批次比较。G0、G1 的两个角色指向同一批次，不能重复计入完整种群。


代	尝试	研究调用	完成稿件	最佳版本通过	通过率
G0	12	169	1	0	0.0%
G1	16	155	5	1	6.25%
G2	16	148	8	5	31.25%
G3	20	158	14	9	45.0%
合计	64	630	28	15	23.4%

表 7: G0–G3 完整种群计数。失败和未完成尝试保留在分母中，所选批次与整体表现分别报告。

G3 所选策略通过率为 75% (3/4)，初始策略为 50% (2/4)。计入当代全部候选与初始策略后，G3 整代为 45% (9/20)；整个窗口为 $15/64 = 23.4\%$ 。只统计完成稿件，则为 $15/28 = 53.6\%$ 。采用所选策略、开展策略搜索与完成稿件后的评价，对应这三种不同的统计范围。

每个通过结果，研究调用减少 52.8%

G3 的两个策略批次各执行四次研究尝试。初始策略使用 41 次研究调用，得到 2 个通过结果；所选策略使用 29 次，得到 3 个通过结果。图9 与表8 将研究、评阅和推算修订放在同一账本中。



G3：每组 4 次尝试。通过采用历史模型评阅规则；修订次数按记录推得。

图 9: G3 每通过结果的研究调用由 $41/2 = 20.50$ 降至 $29/3 = 9.67$ ，减少 52.8%；研究、评阅和推算修订的合计代理由 $86/2 = 43.00$ 降至 $74/3 = 24.67$ ，减少 42.6%。

G3 策略	研究	评阅	修订 *	合计	通过	合计／通过
初始策略	41	36	9	86	2	43.00
所选策略	29	36	9	74	3	24.67

表 8: G3 调用账本，每组四次研究。两个策略批次各有 12 组评阅、36 个独立会话；修订 * 由非初轮评分推算，评阅组数不重复加入合计。

每次研究尝试的研究调用由 $41/4 = 10.25$ 降至 $29/4 = 7.25$ ，通过数同时由 2 增至 3，共同带来每通过研究调用下降 52.8%。计入评阅与推算修订后，合计代理每通过下降 42.6%。两项比值的统计范围见第3.1 节，完整机器费用与人时尚未计入。

把整个搜索过程计入，G0–G3 累计 630 次研究调用和 15 个通过结果，研究调用每通过为 42。这个总账包含寻找策略的投入，与采用 G3 所选策略批次的成本分别报告。零通过批次的每通过调用无定义。

通过定义影响策略比较的解读

我们还用保留的评阅票做了一项更严格的诊断：要求三票均 Accept，且每票评分至少 7。G3 初始与所选策略都只有 1/4 次尝试满足要求。该诊断未重新评阅，说明历史通过规则会影响优势的解读。小批次、自选目标与事后选定的展示窗口，也限制了结果的推广范围；稳定收益仍需匹配任务、统一质量检查和完整资源核算来验证。^[10]

3.4 评分预测：提分与不变可辨，降分仍难判

回应反馈评价器读取论文、初始评阅与作者当时的回应，预测评分上涨、不变或下降。每个案例单独输入模型，最终评分仅用于核对标签，实际变化写为 $\text{sign}(R_{\text{final}} - R_{\text{initial}})$ 。

测试连接公开 OpenReview 历史记录与 ProReviewer 初始评分，采用 DeepSeek V4 Pro、案例隔离、零样本提示和 temperature 0。表9 列出来源报告的聚合结果。Macro-F1 为各类别 F1 的平均，越接近 1 越好。^[1,8,10]

来源与样本	预测设置	Macro-F1
36 例均衡子集	上涨与不变各 18 例，不含下降类	0.805
57 例完整测试	上涨、不变和下降三类，含 6 例下降	0.503
同一 57 例来源集	来源报告的上涨 / 不变二类指标 *	0.755

表 9: 回应评分变化预测。* 第三行来自同一 57 例来源集，有效二类样本分母未单列；三行分别对应不同评价设置。F1 保留来源报告值，公开材料尚不含可重新估计的逐例预测。

36 例均衡二类测试的 Macro-F1 为 0.805；57 例完整三类测试为 0.503，其中下降类 F1 为 0。下降类识别是这一评价器的明显弱点，二类测试中的区分能力无法覆盖它。进一步修改提示未改善留出集表现，因此保留原始零样本提示，未修改模型权重。

EAR 用评分变化预测与证据检查比较草稿。当前测试回答的是能否预测既有回应之后的评分变化；生成的新回应是否提高真实审稿人的评分，还需要单独实验。实际回应决策仍须结合内容、证据和作者判断，尤其要注意评价器对下降类的识别不足。

公开材料与结果核对

公开的计数、分数和及评价协议，可以核对均值、比例、调用总数与每通过成本。匿名过程记录保留了证据改变决策、反馈改变策略的具体转折。公开聚合材料尚不包含个别研究目标、完整稿件、逐票文本、逐例回应预测与完整执行日志；它支持统计核对，完整研究过程的复现还需要这些材料。

4 结论

研究中的下一步，常常由刚得到的证据决定。EAR 把这种推进方式落实到三个工作流程中：问题发现根据近邻文献重新取舍候选；数学内循环沿评审指出的缺口修订研究，外循环用完整研究结果检验执行策略；评审回应围绕疑虑寻找证据，保留有效草稿并继续补齐缺口。研究材料、判断依据和版本变化随过程留下，为继续工作提供基础。

历史记录给出了这些机制的初步证据。固定稿件子集在修订后获得更好的模型评审结果，G3 所选策略在历史批次中取得更多通过结果和更低的每通过研究调用；回应评分预测则同时显示了二类区分能力与下降类识别的不足。每项结果都对应具体任务、分母和评价条件。采用已有策略与继续搜索策略的投入，也需要分别核算。

让研究持续推进，把关键判断留给人

研究者给方向、定标准、检查关键结果。EAR 在这些约束下继续检索、尝试和修订，交回新的产物，以及支持下一步判断的依据。

最终要检验的，是完成可信研究所需的人时。后续评估需要在匹配任务和一致质量检查下，记录阅读、编排、检查、修复、失败返工与最终审阅的投入，并同时核算完整机器费用和日历周期。这样才能回答 EAR 的设计目标在实际使用中实现了多少。

开源项目与公开材料

EAR 开源仓库提供问题发现、自主数学研究与评审回应三个模块。随报告公开的聚合数据、评价协议和矢量图支持核对统计与检查论述；材料的范围与限制见第3.4 节。读者可以据此试用对应流程，核对报告结果，并参与后续改进。^[1,10]

参考文献与公开资料

- [1] EAR contributors. *EAR: Effective Auto Research*. Open-source research automation system, 2026. Problem discovery, autonomous mathematical research and peer-review response.
- [2] Jinheon Baek, Sujay Kumar Jauhar, Silviu Cucerzan and Sung Ju Hwang. *ResearchAgent: Iterative Research Idea Generation over Scientific Literature with Large Language Models*. NAACL, 2025, pp. 6709–6738.
- [3] Chris Lu, Cong Lu, Robert Tjarko Lange, Jakob Foerster, Jeff Clune and David Ha. *The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery*. arXiv:2408.06292, 2024.
- [4] Lakshya A. Agrawal, Shangyin Tan, Dilara Soylu et al. *GEPA: Reflective Prompt Evolution Can Outperform Reinforcement Learning*. arXiv:2507.19457, 2025.
- [5] Qianli Ma, Chang Guo, Zhiheng Tian, Siyu Wang, Jipeng Xiao, Yuanhao Yue and Zhipeng Zhang. *Paper2Rebuttal: A Multi-Agent Framework for Transparent Author Response Assistance*. arXiv:2601.14171, 2026.
- [6] Sophie Leroy. *Why is it so hard to do my work? The challenge of attention residue when switching between work tasks*. Organizational Behavior and Human Decision Processes, 109(2), 168–181, 2009.
- [7] Gloria Mark, Daniela Gudith and Ulrich Klocke. *The Cost of Interrupted Work: More Speed and Stress*. CHI, 2008, pp. 107–110.
- [8] UKP Lab. *ProReviewer Dataset*. Public peer review data. EAR feedback evaluation joins initial and final ratings from this resource and OpenReview.
- [9] Community response resources. *Paper Rebuttal Tips*; *Awesome Rebuttal*; and Devi Parikh, *How we write rebuttals*. Strategy resources used together with author experience.
- [10] EAR report data release. Aggregate research, revision, strategy and feedback evaluation results, with the evaluation protocol accompanying this report. October 2026.